

Отчёт по проекту

Студент: Денисова Алиса Евгеньевна

Группа: БИВ231

1. Введение и постановка задачи

- **Цель проекта:** прогнозировать почасовой спрос на электроэнергию по погодным и календарным признакам
 - **Формулировка задачи:** регрессия
 - **Обоснование метрики качества:** основная метрика качества - `MAE`, потому что она измеряется в тех же единицах, что и нагрузка, и её проще интерпретировать. Дополнительно используется `RMSE` для контроля крупных ошибок
-

2. Поиск и описание данных

- **Источник данных:** датасет Electricity Load Forecasting на Kaggle. Хороший по объему, прикладная задача. Ссылка: <https://www.kaggle.com/datasets/saurabhshahane/electricity-load-forecasting>
 - **Описание датасета:**
 - объём: `48048` строк, `17` столбцов
 - целевой столбец: `nat_demand`
 - временной столбец: `datetime`
-

3. Обработка и подготовка данных

- **Полная очистка:**
 - дубликаты: обнаружено `0`, удаление реализовано
 - пропуски по таргету: `0`, удаление реализовано
 - выбросы: удаление по IQR-правилу ($1.5 * IQR$), удалено `7` строк
 - типы: `datetime` приведен к `datetime`, таргет к `numeric`
- **Работа с фичами:**
 - исходно: `17` признаков/столбцов
 - добавлены признаки: `hour`, `day_of_week`, `month`, `is_weekend`, `lag_1`, `lag_24`, `rolling_mean_24`
 - календарные признаки дают контекст времени, а лаги автозависимость временного ряда
- **Визуализации:**
 - `images/eda_load_curve.png`: фрагмент временного ряда
 - `images/eda_corr_heatmap.png`: матрица корреляций
 - `images/eda_hourly_pattern.png`: средняя нагрузка по часам

- Интерпретация:
 - на кривой нагрузки заметна выраженная суточная сезонность и редкие резкие пики; это объясняет, почему лаговые признаки (`lag_1` , `lag_24`) сильно помогают деревьям
 - по профилю `hourly_pattern` видны вечерние максимумы и ночные минимумы, поэтому признаки `hour` и `is_weekend` уместны и интерпретируемы
 - матрица корреляций показывает высокую связь таргета с лагами и умеренную с погодными факторами
 - Сплит данных:
 - split по времени: `70% train / 15% val / 15% test`
 - shuffle не используется
 - данные из будущего не попадают в train относительно val/test
-

4. Baseline-модель

- **Модель:** `baseline_raw_linear` (`LinearRegression`) без feature engineering
 - **Результаты:**
 - `val_mae = 114.78` , `val_rmse = 139.74`
 - `test_mae = 137.17` , `test_rmse = 167.52`
 - **Цель:** точка отсчёта для сравнения с более сложными моделями
-

5. Эксперименты

1. **Гипотеза:** без FE качество хуже
Проверка: `baseline_raw_linear` vs модели на полном наборе признаков
Результат: baseline без FE значительно хуже по всем метрикам
2. **Гипотеза:** ансамбли деревьев лучше линейных моделей
Проверка: `random_forest` , `xgboost` , `xgb_small` vs `ridge`
Результат: ансамбли дают меньшие MAE/RMSE
3. **Гипотеза:** гиперпараметры влияют на качество
Проверка: добавлен системный тюнинг (`RandomizedSearchCV` + `TimeSeriesSplit`) для `RandomForestRegressor` и `XGBRegressor`
Результат: получены `rf_random_search` и `xgb_random_search` , которые сравниваются с ручными конфигурациями в общей таблице `report/experiments.csv`

Таблица экспериментов:

Модель	Feature set	Val MAE	Val RMSE	Test MAE	Test RMSE
<code>xgb_random_search</code>	<code>full_features</code>	15.63	23.30	21.80	31.43
<code>xgb_small</code>	<code>full_features</code>	15.81	23.46	22.26	31.58
<code>xgboost</code>	<code>full_features</code>	16.20	24.51	24.14	34.81
<code>rf_random_search</code>	<code>full_features</code>	16.45	25.01	23.03	33.44

Модель	Feature set	Val MAE	Val RMSE	Test MAE	Test RMSE
random_forest	full_features	16.54	25.26	23.22	33.90
rf_200	full_features	16.71	25.43	23.35	33.95
baseline_linear	full_features	37.08	49.15	35.81	46.75
ridge	full_features	37.31	49.57	35.76	46.81
knn	full_features	45.47	58.81	68.18	90.51
baseline_raw_linear	raw_only	114.78	139.74	137.17	167.52

6. Финальная модель и интерпретируемость

- **Финальная модель:** `xgb_random_search` (лучший `val_mae` = 15.63 и лучший `test_mae` = 21.80)
- **Интерпретируемость:**
 - результат показывает, что лаговые признаки (`lag_1` , `lag_24` , `rolling_mean_24`) полезны
 - погодные признаки также вносят вклад, но меньше, чем лаги в краткосрочном прогнозе
 - при близком качестве `xgboost` и `random_forest` модель XGBoost выигрывает по точности, а RandomForest может быть предпочтительнее по стабильности и простоте диагностики, в текущий момент tuned-XGBoost уверенно лучше по MAE и на валидации, и на тесте

7. Парсинг

- Добавлен модуль `src/parse_data.py` с ручным парсингом CSV:
- автоопределение разделителя через `csv.Sniffer`
- построчное чтение через `csv.DictReader`
- собственный разбор `datetime` в нескольких форматах
- приведение числовых признаков и таргета к `numeric`
- Этот парсер подключен в пайплайн через `data_tools.load_csv` , поэтому предобработка использует самостоятельный парсинг, а не только `pandas.read_csv`

8. Деплой

FastAPI + Streamlit

После `python src/preprocessing.py` и `python src/modeling.py` появляется `models/best_model.joblib`

FastAPI (`src/api/app.py`):

```
cd src
uvicorn api.app:app --reload --host 127.0.0.1 --port 8000
```

Streamlit (app/streamlit_app.py):

```
streamlit run app/streamlit_app.py --server.port 8501
```

Интерфейс: http://127.0.0.1:8501

Скриншоты

Форма и прогноз:

Прогноз нагрузки

Пример

Лег 1 ч	Лег 24 ч	Средняя 24 ч
1406,56	1366,21	1329,77
Час	День недели	Месяц
20	2	4
Выходной	Температура	Ветер
нет	26,55	25,44
Праздник ID	Праздник	Школа
0	0	1

Спрогнозировать

1,377.00

Swagger:

Electricity Load API 1.0.0 OAS 3.1

/openapi.json

Прогноз почасовой нагрузки

default

GET	/health	Health
GET	/defaults	Defaults
POST	/predict	Predict

Видео

Демонстрация: [Запись](#)


9. Заключение и выводы

- **Итоги:**
- собран воспроизводимый пайплайн подготовки и обучения
- получена рабочая модель с заметным улучшением относительно baseline


- **Ограничения:**
 - интерпретация признаков пока базовая
 - модель обучена на одном датасете, ничего внешнего не использовалось
 - **Возможные улучшения:**
 - расширить подбор гиперпараметров
 - добавить улучшенную интерпретацию
-

10. Приложение: визуализации

Временной ряд нагрузки



Матрица корреляций признаков



Средняя нагрузка по часам

